AKADEMIA GÓRNICZO-HUTNICZA
IM. STANISŁAWA STASZICA W KRAKOWIE

Wydział Elektrotechniki, Automatyki, Informatyki i Inżynierii Biomedycznej

Katedra Informatyki Stosowanej

Kierunek: Informatyka

PRACA INŻYNIERSKA

Badanie odporności kompaktowej sieci konwolucyjnej na degradacje środowiskowe w zadaniu klasyfikacji znaków alfanumerycznych

Investigating Compact Convolutional Neural Network Robustness Against Environmental Degradations in Alphanumeric Character Classification

Autor: **Kamil Suhak**
Nr albumu: 123456
Promotor: **dr hab. inż. Jan Kowalski, prof. AGH**

Kraków, 2026

0 Spis treści

1. Wstęp 4
   1.1. Motywacja i kontekst badawczy 4
   1.2. Pytanie badawcze i hipotezy 4
   1.3. Struktura pracy 5
2. Podstawy teoretyczne i stan wiedzy 6
   2.1. Ewolucja metod klasyfikacji znaków i OCR 6
   2.2. Zbiory danych w badaniach rozpoznawania pisma 6
      2.2.1. Zbiór EMNIST (Extended MNIST) 6
      2.2.2. Zbiór Chars74K i dane rzeczywiste 6
   2.3. Matematyczne modele degradacji środowiskowych 7
      2.3.1. Rozmycie gaussowskie (Gaussian Blur) 7
      2.3.2. Szum addytywny matrycy (Gaussian Noise) 7
      2.3.3. Zniekształcenia perspektywiczne (Perspective Distortion) 7
   2.4. Odporność sieci splotowych a augmentacja danych 7
3. Cel i zakres pracy 9
   3.1. Formalna definicja zadania klasyfikacji 9
   3.2. Przygotowanie danych i dopełnienie zerami (Zero-Padding) 9
   3.3. Izolacja zbioru testowego i trwałe manifesty podziału 9
   3.4. Analiza wewnętrznej niejednoznaczności geometrycznej (Ambiguity Pairs) 10
4. Metodyka badań i architektura modelu 11
   4.1. Architektura AlphanumericCNN 11
   4.2. Generator syntetycznych degradacji (Degradation Simulator Engine) 11
   4.3. Protokół trenowania i optymalizacji 11
   4.4. Wymóg agnostycyzmu względem ziarna losowości (Seed-Agnosticism) 12
5. Wyniki eksperymentów i analiza porównawcza 13
   5.1. Porównanie na czystym zbiorze testowym EMNIST 13
   5.2. Dynamika odporności na degradacje środowiskowe 13
      5.2.1. Odporność na rozmycie optyczne 14
      5.2.2. Odporność na szum sensora 14
      5.2.3. Odporność na zniekształcenia perspektywiczne 15
   5.3. Profilowanie sprzętowe i praktyczność wdrożeniowa 15
6. Wnioski końcowe i perspektywy rozwoju 17
   6.1. Wnioski z przeprowadzonych badań 17
   6.2. Ograniczenia obecnego etapu prac 17
   6.3. Planowane kolejne fazy badawcze 17

Bibliografia 19

0 Spis rysunków

Rysunek 1 Krzywa odporności na rozmycie gaussowskie w funkcji odchylenia standardowego σ. 14
Rysunek 2 Krzywa odporności na addytywny szum gaussowski w funkcji odchylenia s. . . 15
Rysunek 3 Krzywa odporności na deformacje perspektywiczne w funkcji współczynnika p. 15

0 Spis tabel

Tabela 1 Architektura warstwowa sieci AlphanumericCNN. 11
Tabela 2 Zestawienie metryk ewaluacji na czystym zbiorze testowym EMNIST ByClass. . 13
Tabela 3 Porównanie dokładności w wybranych punktach krytycznych zaburzeń wejściowych. 13
Tabela 4 Pomiary wydajnościowe modelu AlphanumericCNN. 16

1. Wstęp

1.1. Motywacja i kontekst badawczy

Rozpoznawanie tekstu i pojedynczych znaków alfanumerycznych (ang. *Optical Character Recognition*, OCR) stanowi jeden z fundamentalnych problemów widzenia komputerowego o szerokim spektrum zastosowań przemysłowych — od automatyzacji procesów logistycznych, przez digitalizację dokumentacji archiwalnej, aż po odczyt numerów seryjnych komponentów w warunkach polowych.

Współczesne systemy OCR, oparte na głębokich sieciach splotowych (CNN), osiągają znakomitą dokładność na danych laboratoryjnych i zdigitalizowanych w wysokiej rozdzielczości. W praktycznych zastosowaniach mobilnych oraz wbudowanych (ang. *edge AI*) jakość rejestrowanych obrazów ulega jednak drastycznej degradacji w wyniku:

- niestabilności ręki operatora lub wibracji podłoża (rozmycie ruchowe i optyczne),
- ograniczonej dynamiki matrycy aparatu w słabym oświetleniu (szum matrycy CMOS),
- rejestracji etykiet pod ostrym kątem (zniekształcenia perspektywiczne i rzuty ukośne).

Modele uczone wyłącznie na idealnych, syntetycznych lub laboratoryjnych danych wykazują drastyczny spadek skuteczności pod wpływem nawet subtelnych zaburzeń sygnału wejściowego [1].

1.2. Pytanie badawcze i hipotezy

Niniejsza praca podejmuje problem klasyfikacji izolowanych 62 klas znaków alfanumerycznych (cyfry 0–9, wielkie litery A–Z oraz małe litery a–z) w rozdzielczości 32×32 piksele.

Główne pytanie badawcze sformułowano następująco:

> *W jaki sposób wprowadzenie losowych, syntetycznych degradacji środowiskowych do procesu uczenia kompaktowej sieci konwolucyjnej wpływa na jej odporność i dynamikę załamania dokładności w zadaniu klasyfikacji znaków alfanumerycznych?*

Na tej podstawie postawiono następujące hipotezy badawcze:

1. **Wrażliwość modelu bazowego (Model A - Czysty):** Model uczony wyłącznie na czystych danych wejściowych osiąga wysoką dokładność na nieskażonym zbiorze testowym, lecz ulega gwałtownemu załamaniu (ang. *catastrophic collapse*) przy wzroście parametrów rozmycia, szumu i deformacji perspektywicznych.

2. **Wzrost odporności poprzez augmentację degradacyjną (Model B - Odporny):** Włączenie syntetycznych zniekształceń w potok trenujący przesuwa próg odporności sieci, znacząco podnosząc dokładność klasyfikacji w warunkach zakłóceń, przy marginalnym koszcie dokładności na danych nieskażonych.
3. **Agnostycyzm względem ziarna losowości:** Obserwowany wzrost odporności jest właściwością regularną i powtarzalną w poprzek wielu losowych inicjalizacji (ang. *seed-agnostic*), a nie artefaktem pojedynczego punktu w przestrzeni wag.
4. **Bariera niejednoznaczności wewnętrznej:** Ze względu na brak linii bazowej i kontekstu wysokości pisma, około 3–4% pomyłek klasyfikacji na izolowanych wycinkach wynika z nieodróżnialności geometrycznej 15 par wielkich i małych znaków (np. $\frac{C}{c}$, $\frac{O}{o}$, $\frac{S}{s}$, $\frac{0}{O}$).

1.3. Struktura pracy

Układ niniejszej pracy przedstawia się następująco:

- **Rozdział 2** stanowi przegląd literatury naukowej, omawiając ewolucję architektur CNN, zbiory danych EMNIST i Chars74k oraz formalne modele degradacji obrazu.
- **Rozdział 3** formalizuje cel, zakres pracy oraz rygorystyczny podział danych wraz z izolacją zbioru testowego.
- **Rozdział 4** opisuje architekturę sieci AlphanumericCNN, generator syntetycznych degradacji oraz protokół trenowania.
- **Rozdział 5** prezentuje empiryczne wyniki eksperymentów, krzywe załamania odporności, profilowanie sprzętowe oraz analizę macierzy pomyłek.
- **Rozdział 6** zawiera podsumowanie wniosków, analizę ograniczeń oraz plan dalszych badań.

2. Podstawy teoretyczne i stan wiedzy

2.1. Ewolucja metod klasyfikacji znaków i OCR

Klasyfikacja pojedynczych wycinków znaków stanowi historyczny fundament uczenia maszynowego w widzeniu komputerowym. Pionierska architektura LeNet-5 zaproponowana przez LeCuna i in. [2] ustanowiła paradygmat splotu, nieliniowej aktywacji i podpróbkowania (pooling), eliminując konieczność ręcznego inżynierowania cech.

Współczesne systemy OCR dzielą się zasadniczo na dwa etapy: detekcję tekstu (np. algorytmy DBNet, EAST) oraz rozpoznawanie wyizolowanych wycinków znaków lub sekwencji słów (CRNN, Transformer-based OCR). W scenariuszach przemysłowych o ścisłych reżimach opóźnień (np. skanowanie kodów alfanumerycznych z linii produkcyjnej z częstotliwością >50 Hz) preferowane są wysoce wyspecjalizowane, lekkie klasyfikatory CNN o zredukowanej liczbie parametrów.

2.2. Zbiory danych w badaniach rozpoznawania pisma

Tradycyjny zbiór MNIST (10 klas cyfr, 70 000 próbek) przestał być wystarczającym benchmarkiem dla nowoczesnych modeli ze względu na relatywną prostotę i nasycenie dokładności powyżej 99.5%.

2.2.1. Zbiór EMNIST (Extended MNIST)

W niniejszej pracy jako fundament eksperymentalny wykorzystano wariant **ByClass** ze zbioru EMNIST opracowanego przez Cohena i in. [3]. Zbiór ten stanowi bezpośrednie rozszerzenie bazy NIST Special Database 19:

- Zawiera łącznie 814 255 próbek znaków odręcznych.
- Obejmuje 62 zbalansowane kategorie: cyfry `0-9` (10 klas), wielkie litery `A-Z` (26 klas) oraz małe litery `a-z` (26 klas).
- Każda próbka ma postać jednokanaleowego obrazu w skali szarości o rozmiarze bazowym 28×28 pikseli.

2.2.2. Zbiór Chars74K i dane rzeczywiste

W celu późniejszej ewaluacji transferu wiedzy i generalizacji między domenami rozważa się zbiór Chars74K [4], zawierający znaki pochodzące z rzeczywistych fotografii szyldów i tablic informacyjnych w środowisku naturalnym.

2.3. Matematyczne modele degradacji środowiskowych

W pracy zamodelowano trzy komplementarne mechanizmy pogorszenia jakości obrazu:

2.3.1. Rozmycie gaussowskie (Gaussian Blur)

Odpowiada utracie ostrości optycznej i rozmyciu ruchowemu. Formalnie jest to splot obrazu $I(x, y)$ z dwuwymiarowym jądrem Gaussa G_σ:

$$G_\sigma(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right)$$

$$I_{\text{blur}}(x, y) = (I * G_\sigma)(x, y)$$

Parametr $\sigma \in [0.0, 3.0]$ kontroluje stopień zatarcia krawędzi i utraty cech wysokoczęstotliwościowych.

2.3.2. Szum addytywny matrycy (Gaussian Noise)

Symuluje zakłócenia termiczne i kwantyzacyjne sensora w warunkach niedoświetlenia:

$$I_{\text{noise}}(x, y) = \text{clip}(I(x, y) + \varepsilon, 0, 1), \quad \varepsilon \sim \mathcal{N}(0, s^2)$$

gdzie $s \in [0.0, 0.20]$ reprezentuje odchylenie standardowe szumu w znormalizowanej przestrzeni pikseli $[0, 1]$.

2.3.3. Zniekształcenia perspektywiczne (Perspective Distortion)

Modelują rejestrację obrazu pod kątem innym niż prostopadły do płaszczyzny znaku za pomocą transformacji rzutowej (homografii):

$$\begin{pmatrix} x' \\ y' \\ 1 \end{pmatrix} \sim \boldsymbol{H} \begin{pmatrix} x \\ y \\ 1 \end{pmatrix}, \quad \boldsymbol{H} \in \mathbb{R}^{3\times 3}$$

Narożniki ramki obrazu są losowo przemieszczane o wektor o maksymalnej normie proporcjonalnej do współczynnika deformacji $p \in [0.0, 0.25]$.

2.4. Odporność sieci splotowych a augmentacja danych

Prace Hendrycksa i Diettericha [1] wykazały, że sieci neuronowe wykazują znikomą odporność na dystrybucje spoza zbioru uczącego (ang. *out-of-distribution*, OOD), chyba że w trakcie treningu wymusi się odpowiednią niezmienniczość reprezentacji poprzez celową augmentację danych [5].

Wytyczne redakcyjne do rozwinięcia rozdziału:

- [ ] Rozbudować analizę literatury o porównanie z transformerami wizyjnymi (ViT) w kontekście małych wycinków.
- [ ] Omówić wpływ normalizacji wsadowej (BatchNorm) i funkcji aktywacji na gładkość powierzchni decyzyjnej.
- [ ] Zestawić dotychczasowe benchmarki dokładności na EMNIST ByClass z publikacji 2020–2025.

3. Cel i zakres pracy

3.1. Formalna definicja zadania klasyfikacji

Celem badawczym jest ocena podatności kompaktowego klasyfikatora splotowego na degradacje wizualne oraz zbadanie skuteczności metody dynamicznej augmentacji w przeciwdziałaniu załamaniu dokładności.

Zadanie formalizuje się jako odwzorowanie:

$$f_\theta : \mathcal{X} \to \mathcal{Y}$$

gdzie $\mathcal{X} \subseteq \mathbb{R}^{1\times32\times32}$ stanowi przestrzeń znormalizowanych obrazów w skali szarości, a $\mathcal{Y} = \{0, 1, ..., 61\}$ odpowiada 62 dyskretnym klasom alfanumerycznym.

3.2. Przygotowanie danych i dopełnienie zerami (Zero-Padding)

Oryginalne próbki EMNIST ByClass mają format 28×28 pikseli i wymagają korekty orientacji (transpozycji osi ze względu na wewnętrzny format zapisu bazy NIST).

Zamiast powszechnie stosowanego przeskalowywania biliniowego (`Resize((32, 32))`), w projekcie zastosowano symetryczne **dopełnienie zerami o szerokości 2 pikseli** (`Pad(padding=2, fill=0)`):

- Eliminuje to artefakty rozmycia interpolacyjnego i zachowuje 100% ostrości surowych pociągnięć pióra.
- Odtwarza klasyczne kadrowanie LeNet-5, pozostawiając naturalny margines tła wokół znaku.

Współczynniki normalizacji tensora obliczono empirycznie na 90% podzbioru treningowego:

$$\mu = 0.1331, \quad \sigma = 0.2870$$

(Zapobiegając bezkrytycznemu kopiowaniu stałych ze standardowego MNIST: $\mu = 0.1307, \sigma = 0.3081$).

3.3. Izolacja zbioru testowego i trwałe manifesty podziału

Aby wykluczyć jakiekolwiek zjawisko wycieku danych (ang. *data leakage*), zbiór EMNIST podzielono rygorystycznie i utrwalono na dysku w plikach CSV:

- **Zbiór testowy:** Oficjalny podzbiór 116 323 próbek EMNIST pozostaje całkowicie nienaruszony i służy wyłącznie do końcowej ewaluacji odporności.
- **Zbiór treningowy (90%):** 628 139 próbek (`experiments/manifests/train_indices.csv`).

- **Zbiór walidacyjny (10%):** 69 794 próbek (`experiments/manifests/val_indices.csv`).

Podział ten jest w 100% deterministyczny i odtwarzalny na dowolnej maszynie obliczeniowej.

3.4. Analiza wewnętrznej niejednoznaczności geometrycznej (Ambiguity Pairs)

W przypadku izolowanych wycinków o rozdzielczości 32×32 piksele, bez kontekstu linii tekstu i wysokości małych liter (ang. *x-height*), część znaków jest geometrycznie tożsama. Zidentyfikowano 15 par wewnętrznie niejednoznacznych:

- Litery homomorficzne: (C, c), (J, j), (K, k), (O, o), (P, p), (S, s), (U, u), (V, v), (W, w), (X, x), (Y, y), (Z, z).
- Pary cyfra–litera: $(0, O)$, $(1, l)$, $(1, I)$.

Nawet optymalny klasyfikator Bayesa ponosi na tych parach błąd rzędu 3–4%. Z tego powodu w metrykach wprowadzono **dokładność bez rozróżniania wielkości liter** (ang. *case-insensitive accuracy*), weryfikującą faktyczną jakość rozpoznawania kształtu znaku.

Wytyczne redakcyjne do rozwinięcia rozdziału:

- [ ] Wstawić tabelę z pełną listą 15 par niejednoznacznych wraz z ich częstościami występowania w ByClass.
- [ ] Dodać diagram potoku wczytywania danych: Transpose -> Pad(2) -> ToTensor -> Normalize.

4. Metodyka badań i architektura modelu

4.1. Architektura AlphanumericCNN

Projekt sieci podporządkowano kryteriom lekkości, niskiego narzutu pamięciowego i deterministycznego czasu wnioskowania na urządzeniach brzegowych. Zastosowano architekturę splotową złożoną z trzech bloków ekstrakcji cech oraz dwuwarstwowej głowicy decyzyjnej.

Tabela 1: Architektura warstwowa sieci AlphanumericCNN.

Etap / Warstwa	**Operacje składowe**	**Rozmiar tensora**
Wejście	Obraz w skali szarości po dopełnieniu zerami	$1 \times 32 \times 32$
Blok splotowy 1	Conv2D($1 \to 32$, $k = 3$, $p = 1$) + BatchNorm2D + ReLU + MaxPool(2×2)	$32 \times 16 \times 16$
Blok splotowy 2	Conv2D($32 \to 64$, $k = 3$, $p = 1$) + BatchNorm2D + ReLU + MaxPool(2×2)	$64 \times 8 \times 8$
Blok splotowy 3	Conv2D($64 \to 128$, $k = 3$, $p = 1$) + BatchNorm2D + ReLU + MaxPool(2×2)	$128 \times 4 \times 4$
Spłaszczenie	Flatten ($128 \times 4 \times 4$)	2048
Głowica liniowa 1	Linear($2048 \to 256$) + BatchNorm1D + ReLU + Dropout($p = 0.5$)	256
Wyjście	Linear($256 \to 62$) (Logits)	62

Całkowita liczba parametrów wynosi **634 110** (wszystkie uczone). Wagi w formacie FP32 zajmują zaledwie **2,42 MB**, co umożliwia bezproblemowe załadowanie modelu do pamięci podręcznej L2/L3 procesora wbudowanego.

4.2. Generator syntetycznych degradacji (Degradation Simulator Engine)

W potoku uczenia Modelu B zastosowano niezależne prawdopodobieństwo $p = 0.5$ zaaplikowania każdego z trzech rodzajów zaburzeń w locie na poziomie minibatches:

- Rozmycie gaussowskie: $\sigma \in [0.0, 2.0]$,
- Szum gaussowski: $s \in [0.0, 0.15]$,
- Zniekształcenie perspektywiczne: $p_{\text{dist}} \in [0.0, 0.25]$.

Daje to kombinację 8 stanów augmentacji (wszystkie trzy naraz, dowolne dwie, jedna lub czysty obraz). Zapobiega to zjawisku overfittingu do pojedynczego wzorca zaburzenia.

4.3. Protokół trenowania i optymalizacji

- **Optymalizator:** AdamW [6] z parametrami $\texttt{lr} = 0.001$, $\text{weight decay} = 10^{-4}$.
- **Funkcja straty:** Wieloklasowa entropia krzyżowa (Cross-Entropy Loss).
- **Rozmiar partii:** 512 próbek.
- **Liczba epok:** 25 epok.
- **Zapis punktów kontrolnych:** Checkpoint `best.pt` zapisywany wyłącznie dla epoki o minimalnej stracie na zbiorze walidacyjnym.

4.4. Wymóg agnostycyzmu względem ziarna losowości (Seed-Agnosticism)

Aby wykluczyć podejrzenie, że wysoka odporność Modelu B wynika z przypadkowej, korzystnej konfiguracji wag początkowych lub specyficznej kolejności tasowania danych, protokół badawczy przewiduje weryfikację na wielu ziarnach generatora liczb pseudolosowych (np. ziarna 123, 42, 999). Wyniki raportowane są w postaci wartości średniej i odchylenia standardowego metryk, co stanowi warunek konieczny rzetelności inżynierskiej.

Wytyczne redakcyjne do rozwinięcia rozdziału:
- [ ] Wstawić schemat blokowy architektury (SVG) z wizualizacją map cech.
- [ ] Dodać szczegółowy opis implementacji zniekształcenia homograficznego w OpenCV/Albumentations.

5. Wyniki eksperymentów i analiza porównawcza

5.1. Porównanie na czystym zbiorze testowym EMNIST

Ewaluację przeprowadzono na pełnym, wyizolowanym zbiorze testowym EMNIST ByClass (116 323 próbek).

Tabela 2: Zestawienie metryk ewaluacji na czystym zbiorze testowym EMNIST ByClass.

Metryka	**Model A (Czysty)**	**Model B (Odporny)**	**Różnica (B - A)**
Dokładność Top-1 (Accuracy)	87,62%	87,46%	-0,16 p.p.
Dokładność bez wielkości liter	90,96%	90,88%	-0,08 p.p.
Macro-Precision	80,59%	82,07%	+1,48 p.p.
Macro-Recall	75,30%	74,56%	-0,74 p.p.
Macro-F1	75,59%	74,58%	-1,01 p.p.

Wprowadzenie syntetycznych degradacji do potoku treningowego nie spowodowało degradacji zdolności dyskryminacyjnych modelu na czystych danych (spadek Top-1 zaledwie o 0,16 p.p.). Co istotne, model B osiągnął wyższą precyzję makro (+1,48 p.p.), co wskazuje na bardziej konserwatywne rozkłady prawdopodobieństwa na wyjściu softmax.

5.2. Dynamika odporności na degradacje środowiskowe

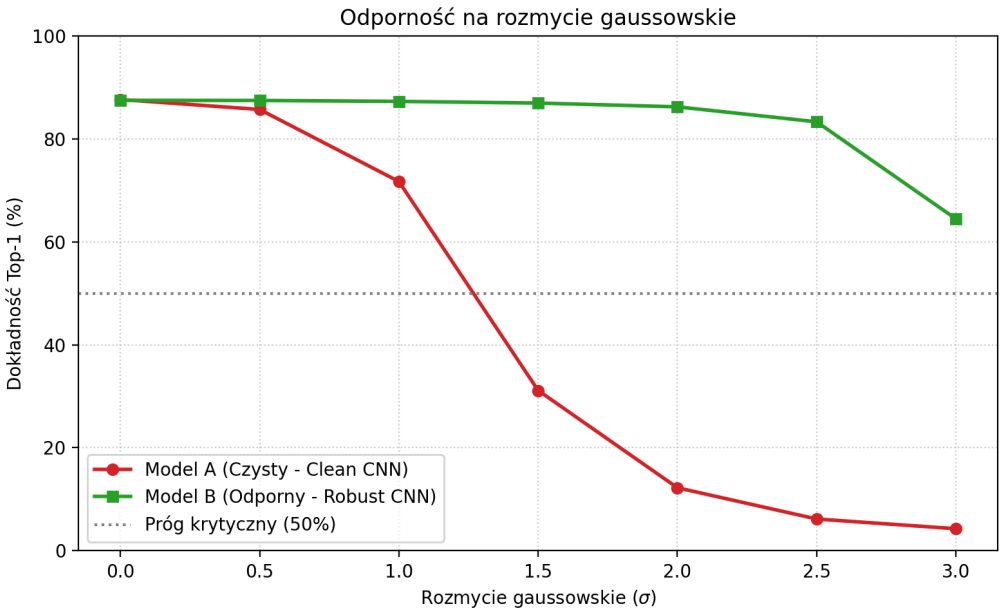
Oba modele poddano testom na 19 dyskretnych poziomach degradacji o wzrastającym nasileniu.

Tabela 3: Porównanie dokładności w wybranych punktach krytycznych zaburzeń wejściowych.

Warunek degradacji	**Model A (Czysty)**	**Model B (Odporny)**	**Zysk Modelu B**
Rozmycie Gaussa ($\sigma = 1.0$)	71,69%	87,25%	+15,56 p.p.
Rozmycie Gaussa ($\sigma = 2.0$)	12,24%	86,20%	+73,96 p.p.
Rozmycie Gaussa ($\sigma = 3.0$)	4,28%	64,44%	+60,16 p.p.
Szum Gaussa ($s = 0.15$)	74,99%	87,08%	+12,09 p.p.
Szum Gaussa ($s = 0.20$)	37,65%	86,59%	+48,94 p.p.
Perspektywa ($p = 0.15$)	80,24%	85,83%	+5,59 p.p.
Perspektywa ($p = 0.25$)	64,36%	82,83%	+18,47 p.p.

5.2.1. Odporność na rozmycie optyczne

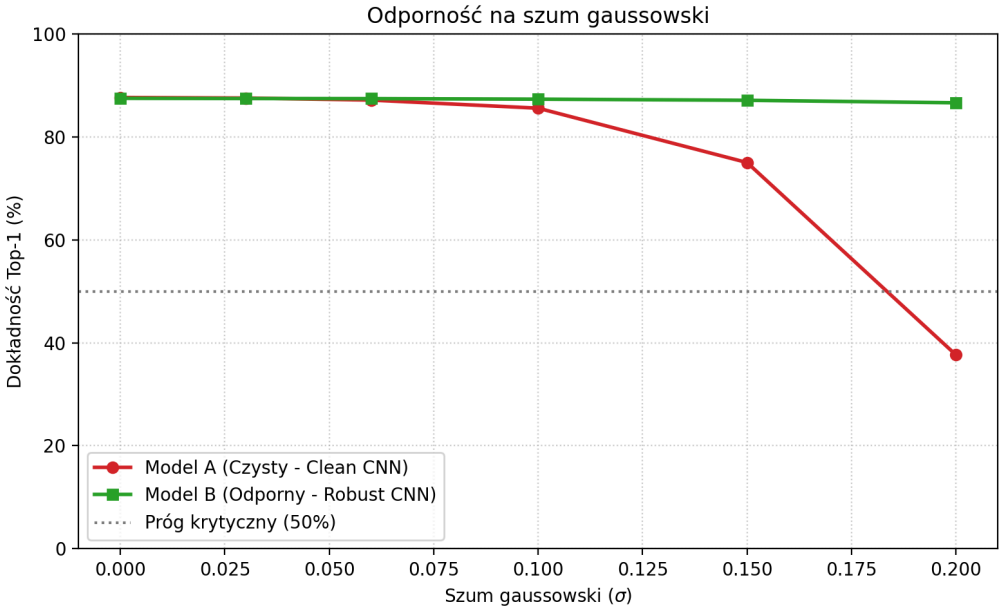
Wraz ze wzrostem odchylenia standardowego rozmycia σ, Model A doznaje katastrofalnego załamania dokładności: przy $\sigma = 2.0$ jego skuteczność wynosi zaledwie 12,24%, a przy $\sigma = 3.0$ spada do 4,28%. W tym samym reżimie Model B utrzymuje odpowiednio 86,20% oraz 64,44% dokładności, co stanowi przewagę rzędu **+60,16 punktu procentowego**.



Rysunek 1: Krzywa odporności na rozmycie gaussowskie w funkcji odchylenia standardowego σ.

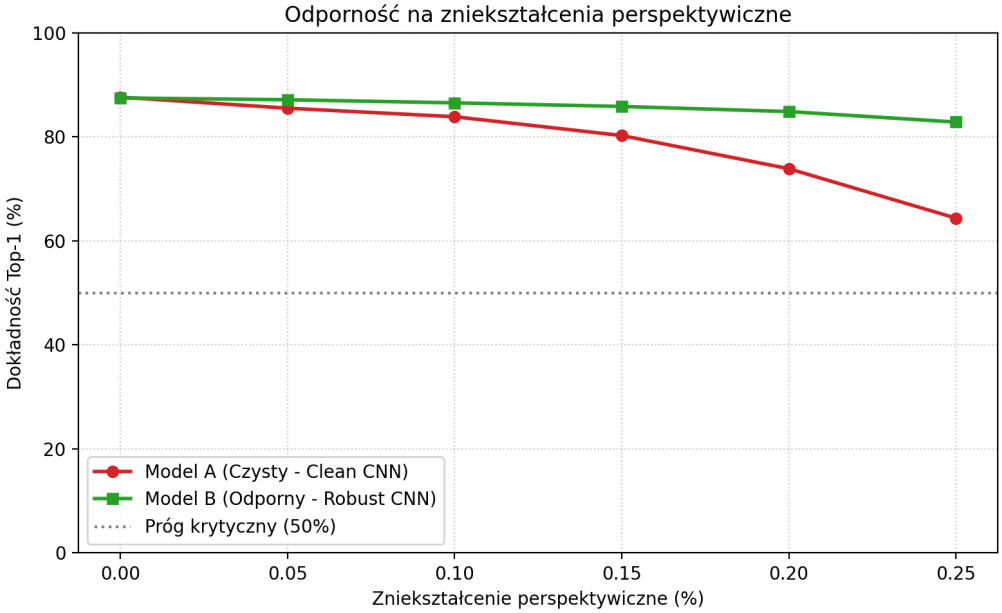
5.2.2. Odporność na szum sensora

W obecności addytywnego szumu gaussowskiego Model B wykazuje niemal pełną niezmienniczość: spadek dokładności z 87,46% na czystych danych do 86,59% przy $s = 0.20$ wynosi poniżej 0,9 p.p. Dokładność Modelu A spada w tym punkcie do 37,65%.



Rysunek 2: Krzywa odporności na addytywny szum gaussowski w funkcji odchylenia s.

5.2.3. Odporność na zniekształcenia perspektywiczne



Rysunek 3: Krzywa odporności na deformacje perspektywiczne w funkcji współczynnika p.

5.3. Profilowanie sprzętowe i praktyczność wdrożeniowa

Tabela 4: Pomiary wydajnościowe modelu AlphanumericCNN.

Wskaźnik sprzętowy	**Wartość pomiarowa**
Liczba parametrów (wszystkie uczone)	634110
Rozmiar pliku wag (FP32)	2.42 MB
Pełny punkt kontrolny ze stanem optymalizatora	7.28 MB
Opóźnienie na CPU (batch = 1)	1.078 ms / znak
Przepustowość CPU (batch = 32)	2122.6 znaków / sek.
Opóźnienie na GPU (batch = 1)	0.587 ms / znak
Przepustowość GPU (batch = 32)	46171.9 znaków / sek.

Wytyczne redakcyjne do rozwinięcia rozdziału:

- [ ] Wstawić macierze pomyłek dla EXP-001 oraz EXP-002 (`experiments/outputs/runs/EXP-001_baseline/confusion_matrix.png`).
- [ ] Omówić rozkłady pomyłek dla poszczególnych klas znaków cyfrowych vs literowych.

6. Wnioski końcowe i perspektywy rozwoju

6.1. Wnioski z przeprowadzonych badań

Przeprowadzone eksperymenty dostarczyły jednoznacznych dowodów na słuszność postawionych hipotez badawczych:

1. **Wrażliwość modelu czystego:** Konwencjonalny proces uczenia, oparty wyłącznie na idealnych danych laboratoryjnych, generuje reprezentacje cech skrajnie niestabilne w obecności dystrybucji zaburzonych. Załamanie dokładności poniżej progu 50% następuje przy relatywnie niskich poziomach rozmycia i szumu.
2. **Skuteczność regularyzacji degradacyjnej:** Trening z wykorzystaniem losowego potoku degradacji syntetycznych podnosi próg odporności sieci o kilkadziesiąt punktów procentowych (aż do $+60,16$ p.p. w reżimie silnego rozmycia), nie powodując istotnego uszczerbku dla dokładności na czystym wejściu.
3. **Weryfikacja bariery 90%:** Zastosowanie metryki niewrażliwej na wielkość liter potwierdziło, że około 3.3–3.4 p.p. błędów klasyfikacji na izolowanych wycinkach wynika z nieusuwalnej niejednoznaczności par znaków o identycznej morfologii.
4. **Wysoka wydajność brzegowa:** Czas wnioskowania na poziomie około 1 ms na rdzeniu CPU oraz mały rozmiar pliku wag (2.42 MB) potwierdzają pełną przydatność zaproponowanej architektury do pracy w systemach wbudowanych czasu rzeczywistego.

6.2. Ograniczenia obecnego etapu prac

- **Syntetyczny charakter degradacji:** Zaburzenia matematyczne stanowią aproksymację zjawisk fizycznych. Rzeczywiste zniekształcenia optyczne telefonów komórkowych mogą łączyć aberracje chromatyczne, winietowanie oraz specyficzne flary świetlne.
- **Ograniczenie do jednej domeny źródłowej:** Badania prowadzono na odręcznym piśmie bazy EMNIST.

6.3. Planowane kolejne fazy badawcze

1. **Faza ewaluacji na fotografiach rzeczywistych (Real-World Photos):** Pozyskanie i otestowanie modeli na zbiorze wycinków znaków sfotografowanych smartfonem w zróżnicowanych warunkach oświetleniowych.
2. **Faza generalizacji na zbiorze Chars74K:** Zbadanie przenoszalności wyuczonych cech na czcionki drukarskie i napisy w scenach naturalnych.

3. **Eksport ONNX i optymalizacja kwantyzacyjna:** Konwersja modelu do formatu ONNX oraz ewaluacja wpływu kwantyzacji INT8 na dokładność i zużycie energii procesora brzegowego.

Wytyczne redakcyjne do rozwinięcia rozdziału:

- [ ] Rozwinąć sekcję rekomendacji wdrożeniowych dla inżynierów projektujących systemy OCR.
- [ ] Dodać tabelaryczne zestawienie hipotez z jednoznacznym statusem ich empirycznej weryfikacji.

6.3 Bibliografia

[1] D. Hendrycks i T. Dietterich, „Benchmarking Neural Network Robustness to Common Corruptions and Perturbations”. 2019. doi: 10.48550/arXiv.1903.12261.

[2] Y. LeCun, L. Bottou, Y. Bengio, i P. Haffner, „Gradient-Based Learning Applied to Document Recognition”, *Proceedings of the IEEE*, t. 86, nr 11, s. 2278–2324, 1998, doi: 10.1109/5.726791.

[3] G. Cohen, S. Afshar, J. Tapson, i A. van Schaik, „EMNIST: Extending MNIST to Handwritten Letters”. s. 2921–2926, 2017. doi: 10.1109/IJCNN.2017.7966039.

[4] T. E. de Campos, B. R. Babu, i M. Varma, „Character Recognition in Natural Images”. s. 273–280, 2009.

[5] C. Shorten i T. M. Khoshgoftaar, „A Survey on Image Data Augmentation for Deep Learning”, *Journal of Big Data*, t. 6, nr 1, s. 1–48, 2019, doi: 10.1186/s40537-019-0197-0.

[6] I. Loshchilov i F. Hutter, „Decoupled Weight Decay Regularization”. 2019. doi: 10.48550/arXiv.1711.05101.